0

# APRENDIZAJE POR REFUERZO II (CURSADO)

# DOCENTE DEL CURSO

- Miguel Augusto Azar
- Ingeniero en Informática
- Especialista en Docencia Superior
- Docente e investigador
- Email: augusto.azar@gmail.com

# RECURSOS VIRTUALES

- Campus virtual

https://campusposgrado.fi.uba.ar/course/view.php?id=415

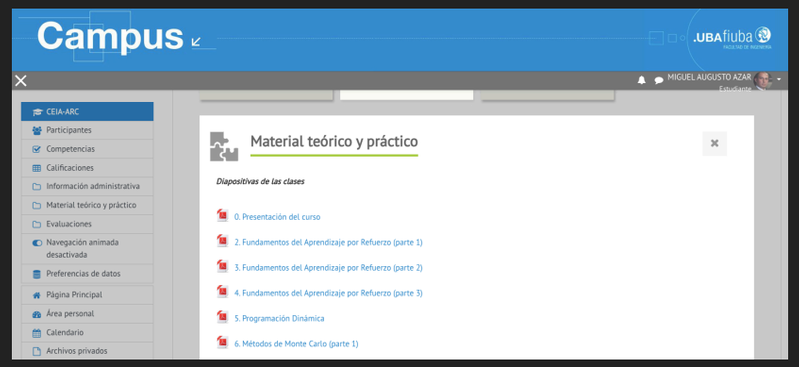


- Repositorio

https://github.com/aear-uba/ar2/

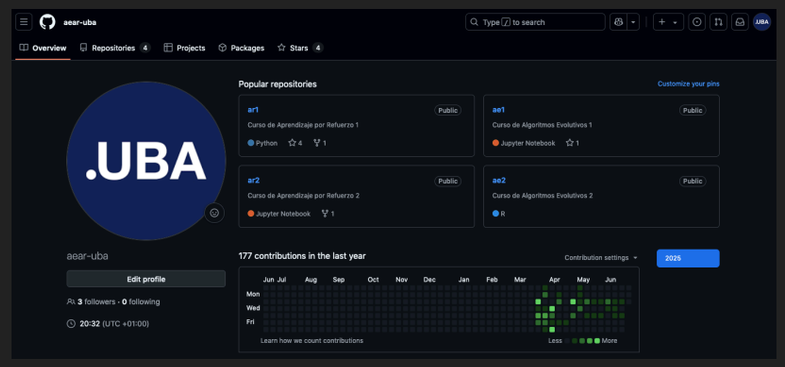

# ¿EN QUÉ CONSISTE APRENDIZAJE POR REFUERZO II?

- Consiste en el estudio y desarrollo de algoritmos inteligentes que aprenden por sí mismos (o asistidos) una determinada tarea.

.UBAfiuba FACULTAD DE INGENIERÍA

# TÉCNICAS DE RL A ABORDAR EN EL CURSO

- A3C, A2C
- DDPG
- TRPO, PPO
- SAC
- IQL, VDN, QMIX

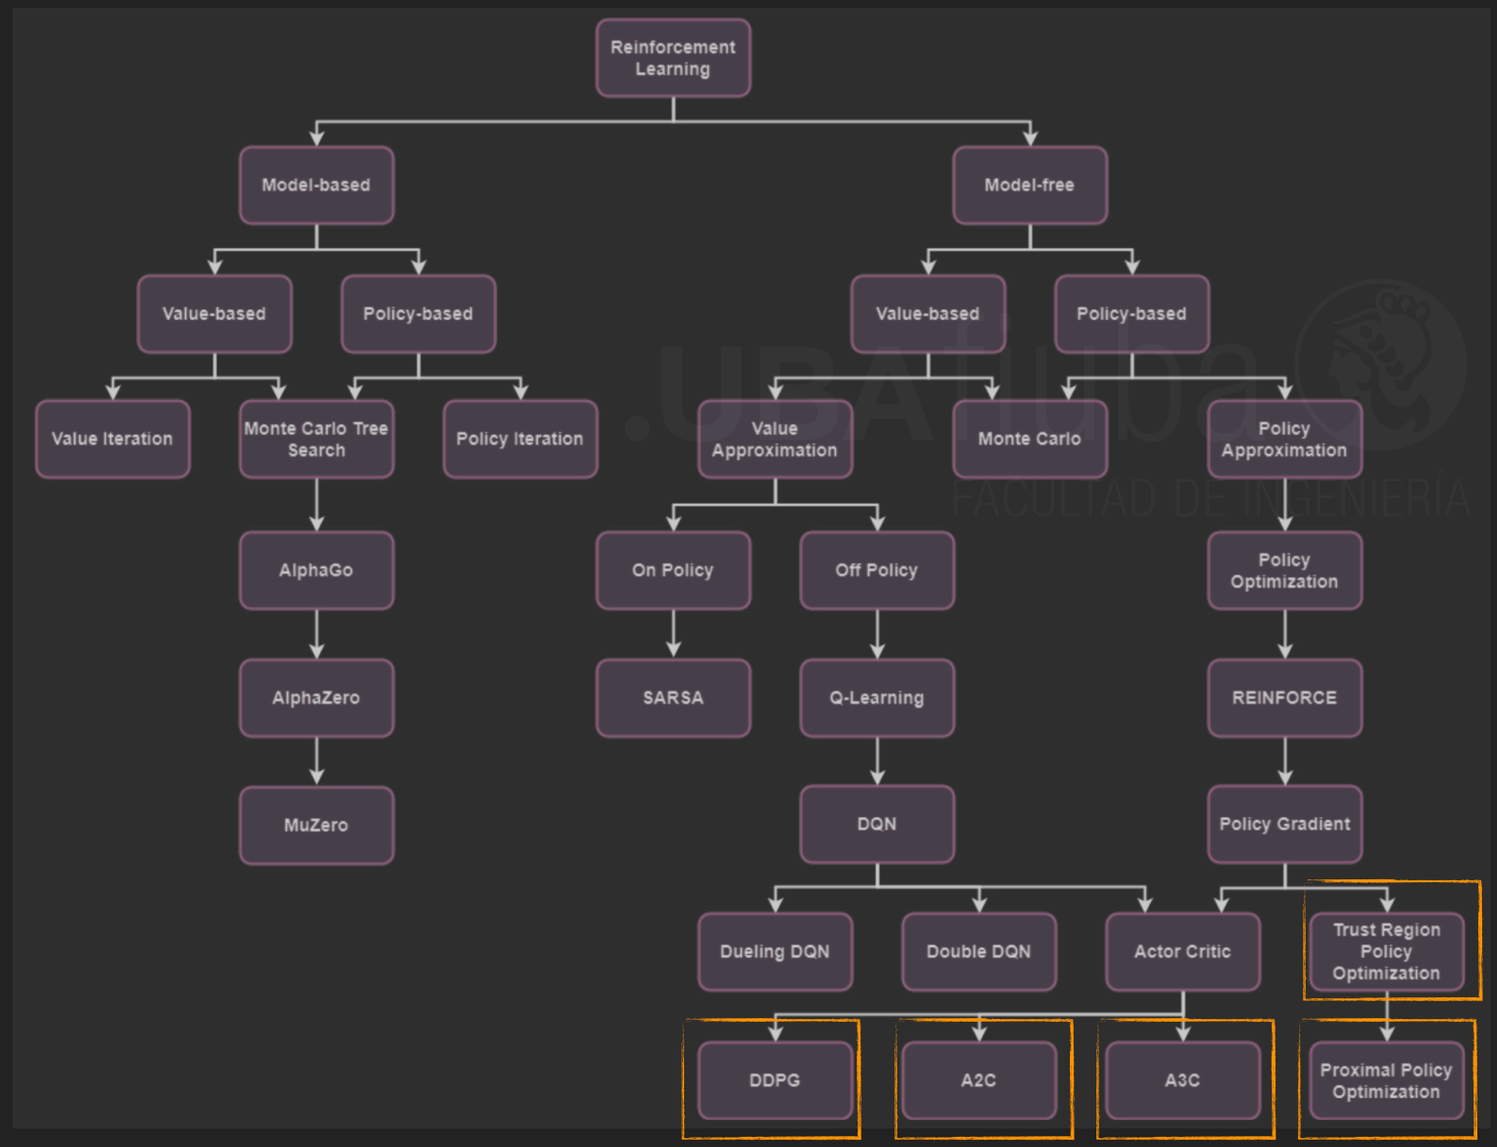

# TEMAS A ABORDAR EN EL CURSO

- Variantes de Actor-Critic. A2C, A3C, SAC, DDPG, TRPO, PPO, TD3, IMPALA. Estimación de V(s). Varianza y Bias. Retornos de AC, A2C y Monte Carlo. Actor-Critic One-Step. Pseudocódigo. Cuando usar Actor-Critic. Ejemplo. Asynchronous Advantage Actor-Critic (A3C). Cómo funciona A3C. Función de Ventaja A(s, a). Arquitectura de varios actores. Actor-learners o Workers. Global networking. Problemas de A3C. Advantage Actor-Critic (A2C). Contribuciones de A2C. Ejemplo con Stable-Baseline 3 (SB3). Parámetros en SB3.
- Deep Deterministic Policy Gradient (DDPG). Introducción y ejemplo de un brazo robótico. Espacio de aci´ón continua. Deterministic Policy Gradient Algorithm (DPG). Arquitectura básica de DDPG. Componentes de DDPG. Ruido para exploración. Ornstein-Uhlenbeck Noise. Cómo funciona DDPG. Generación de trayectorias. Entrenamiento del Crítico. Entrenamiento del Actor. Actualización suave de redes objetivo. Polyak Averaging (interpolación lenta o soft update). Ventajas de DDPG. Pseudocódigo y arquitectura detallada. Ejemplo con SB3. Parámetros en SB3. Ejemplo real a nivel prototipo de un coche autónomo. Arquitectura. Entrada, Procesamiento, Vector de Estado, Recompensa. Variables simuladas vs variables reales. Espacio de estados. Tratamiento de la imagen. Espacio de acciones bidimensionales. Arquitectura de entrenamiento basada en tareas.
- Trust Region Policy Optimization (TRPO). El problema de los algoritmos de gradiente de política. Analogía de TRPO. Arquitectura de TRPO. Pseudcódigo de TRPO. Cálculo de la función de Ventaja. Generalized Advantage Estimation. Cálculo del objetivo sustituto (Surrogate Objective). Interpretación del objetivo sustituto. Optimización de L mediante Región de Confianza. Cómo se obtiene $\Delta\theta$ usando gradiente conjugado. Limitaciones de TRPO. Proximal Policy Optimization (PPO). Arquitectura de PPO. Cómo funciona el recorte (Clipping). Pérdida total en PPO. Comparativa de PPO vs TRPO. Ejemplo de PPO con SB3. Parámetros de SB3. Aplicación de PPO. Fases del pipeline de RLHF.
- Reinforcement Learning from Human Feedback (RLHF). Problemas de los LLM. Ciclo de vida de RLHF. Ajuste fino supervisado (SFT). Entrenamiento de un modelo de recompensa. Optimización de LLM con PPO. Instruct GPT. Hallucination. Toxicidad. Bias. Alignment Tax. Métrica Winogender. Crows-Pairs. Stanford Question Answering Dataset (SQuAD). Discrete Reasoning Over Paragraph (DROP). Resultados relevantes del método RLHF. Ejemplo de afinación con PPO. Configuración inicial. Configuración de la generación de texto. Definición de la recompensa. Preparación del entrenamiento. Entrenamiento con PPO. Generación post-entrenamiento. Direct Preference Optimization (DPO). Modelos de Lenguaje de Razonamiento (RLM).

# TEMAS A ABORDAR EN EL CURSO

- Soft Actor-Critic (SAC). Contribuciones de SAC. Analogía para interpretar SAC. Características de SAC. Pseudocódigo y arquitectura de SAC. Ejemplo con SB3. Parámetros de SB3. SAC-V2.
- Multi-Agent Reinforcement Learning (MARL). Tipos de entorno multiagente. Ejemplo de 3 drones. Arquitectura descentralizada. Cobertura. Arquitectura descentralizada con Q-Learning. Agente RLlib y entorno PetingZoo. Otros entornos en PettingZoo. MPE. SISL. Waterworld y sus características técnicas. Configuración del PPO. Cobertura. Waterworld cooperativo. Arquitectura centralizada. Independent Q-Learning (IQL). Value Decomposition Network (VDN). QMIX. Juegos estocásticos y Juegos en forma extensiva. Estrategias competitivas, cooperativas y mixtas. Comportamiento competitivo. Teoría de Juegos. Puntos de equilibrio en juegos de N personas. Tipos de juegos. Equilibrio de Nash. Dilema del prisionero. Matriz de pagos. Equilibrio de Nash puro. Comportamiento cooperativo. MDP parcialmente observable descentralizado (Dec-POMDP). Características de un Dec-POMDP. Modelado de un POMDP. Modelado de Dec-POMDP. Optimización multiobjetivo. Solución y Frente de Pareto. Dominancia. Eficiencia de Pareto. Nash, Pareto y el Dilema del prisionero. Comportamiento competitivo. Juegos de suma cero. Competencia pura por recursos. Cazador único / Botín único (Winner Takes All o Race to the Bottom. Ambientes de eliminación. Juegos adversariales parcialmente observables. Competencia asimétrica. Competencia Multi-etapa o de largo plazo. Competencia con manipulación de entorno. Comportamiento mixto. Juegos de negociación o comercio (Bargaining / Trade Games). Subastas (Auctions). Biblioteca OpenSpiel. Juegos sociales con reputación. Biblioteca MeltingPot. Recursos compartidos (Common-Pool resources). Juego de caza de ciervos (Stag hunt). Juegos de entrega en red (Packet routing / Delivery games). Formación de coaliciones. Predator-Prey.
- Aprendizaje por Imitación (IL). Clonación de comportamiento (Behavior cloning). Aprendizaje por refuerzo inverso (IRL). Minimización de divergencia (mediante GAN). Que es el aprendizaje por refuerzo inverso. Ejemplo de IRL. Igualación de expectativas de características (Feature Expectation Matching). Pseudocódigo de FEM. Umbral de tolerancia ε. Aprendizaje por Imitación Adversaria Generativa (GAIL). Arquitectura de GAN. Arquitectura de GAIL. Pseudocódigo de GAIL. Ejemplo de GAIL. Métricas del generador y del discriminador.

# CURSADO

- Parte 1 (~ 80 min.)
- Break (~ 10-20 min.)
- Parte 2 (~ 80 min.)

# EVALUACIÓN

- Se aprueba la materia implementando 1 desafío práctico presentado en forma:
  - ✓ Individual.
  - ✓ Grupal (hasta 3 integrantes).
- La entrega consta de:
  - ✓ Informe explicativo de al menos 3 carillas (.pdf).
  - ✓ Código fuente en Python (.py, .ipynb, etc.) transcripto parcialmente en el informe y completo en un repositorio (el enlace al repositorio debe proporcionarse en el informe).
- La modalidad de entrega se realizará:
  - ✓ Durante la cursada o al final subiendo el .pdf al campus de la FIUBA.
  - ✓ Sin exposición en la última clase.
- Los desafíos son abiertos. El estudiante o el grupo elige un caso de uso según una o varias de las técnicas de Aprendizaje por Refuerzo vistas durante la cursada y elabora el desafío práctico.

# REFERENCIAS BIBLIOGRÁFICAS Y WEB (I)


- R. S. Sutton and A. G. Barto, Reinforcement Learning: An Introduction, 2nd ed. Cambridge, MA, USA: MIT Press, 2018.
- https://www.kaggle.com/discussions/getting-started/162377
- Wang, Z., Schaul, T., Hessel, M., Hasselt, H., Lanctot, M., & Freitas, N. (2016, June). Dueling network architectures for deep reinforcement learning. In International conference on machine learning (pp. 1995-2003). PMLR.
- Mnih, V., Badia, A. P., Mirza, M., Graves, A., Lillicrap, T., Harley, T., ... & Kavukcuoglu, K. (2016, June). Asynchronous methods for deep reinforcement learning. In International conference on machine learning (pp. 1928-1937). PmLR.
- Haarnoja, T., Zhou, A., Abbeel, P., & Levine, S. (2018, July). Soft actor-critic: Off-policy maximum entropy deep reinforcement learning with a stochastic actor. In International conference on machine learning (pp. 1861-1870). Pmlr.
- Haarnoja, T., Zhou, A., Hartikainen, K., Tucker, G., Ha, S., Tan, J., ... & Levine, S. (2019). Soft actor-critic algorithms and applications. arXiv preprint arXiv:1812.05905.
- https://github.com/ray-project/ray/tree/master/rllib/tuned_examples/sac
- Silver, D., Lever, G., Heess, N., Degris, T., Wierstra, D., & Riedmiller, M. (2014, January). Deterministic policy gradient algorithms. In International conference on machine learning (pp. 387-395). Pmlr.
- Lillicrap, T. P., Hunt, J. J., Pritzel, A., Heess, N., Erez, T., Tassa, Y. & Wierstra, D. (2015). Continuous control with deep reinforcement learning. arXiv preprint arXiv:1509.02971.
- G. E. Uhlenbeck and L. S. Ornstein, "On the theory of the brownian motion," Phys. Rev., vol. 36, pp. 823–841, Sep 1930.
- Kendall, A., Hawke, J., Janz, D., Mazur, P., Reda, D., Allen, J. M., ... & Shah, A. (2019, May). Learning to drive in a day. In 2019 international conference on robotics and automation (ICRA) (pp. 8248-8254). IEEE.

# REFERENCIAS BIBLIOGRÁFICAS Y WEB (I)


- https://wayve.ai/thinking/learning-to-drive-in-a-day/
- https://www.washingtonpost.com/technology/2019/04/05/watch-self-driving-car-learn-navigate-narrow-european-streets-like-human-driver/
- Schulman, J., Levine, S., Abbeel, P., Jordan, M., & Moritz, P. (2015, June). Trust region policy optimization. In International conference on machine learning (pp. 1889-1897). PMLR.
- Schulman, J., Moritz, P., Levine, S., Jordan, M., & Abbeel, P. (2015). High-dimensional continuous control using generalized advantage estimation. arXiv preprint arXiv:1506.02438.
- Schulman, J., Wolski, F., Dhariwal, P., Radford, A., & Klimov, O. (2017). Proximal policy optimization algorithms. arXiv preprint arXiv:1707.06347.
- Ouyang, L., Wu, J., Jiang, X., Almeida, D., Wainwright, C., Mishkin, P., ... & Lowe, R. (2022). Training language models to follow instructions with human feedback. Advances in neural information processing systems, 35, 27730-27744.
- Vaswani, A., Shazeer, N., Parmar, N., Uszkoreit, J., Jones, L., Gomez, A. N., ... & Polosukhin, I. (2017). Attention is all you need. Advances in neural information processing systems, 30.
- Rajpurkar, P., Jia, R., and Liang, P. (2018). Know what you don't know: Unanswerable questions for squad. arXiv preprint arXiv:1806.03822.
- Dua, D., Wang, Y., Dasigi, P., Stanovsky, G., Singh, S., and Gardner, M. (2019). Drop: A read- ing comprehension benchmark requiring discrete reasoning over paragraphs. arXiv preprint arXiv:1903.00161.
- Rudinger, R., Naradowsky, J., Leonard, B., and Van Durme, B. (2018). Gender bias in coreference resolution. In Proceedings of the 2018 Conference of the North American Chapter of the Association for Computational Linguistics: Human Language Technologies, New Orleans, Louisiana. Association for Computational Linguistics.

# REFERENCIAS BIBLIOGRÁFICAS Y WEB (I)


- Nangia, N., Vania, C., Bhalerao, R., and Bowman, S. R. (2020). CrowS-Pairs: A Challenge Dataset for Measuring Social Biases in Masked Language Models. In Proceedings of the 2020 Conference on Empirical Methods in Natural Language Processing, Online. Association for Computational Linguistics.
- Rafailov, R., Sharma, A., Mitchell, E., Manning, C. D., Ermon, S., & Finn, C. (2023). Direct preference optimization: Your language model is secretly a reward model. Advances in Neural Information Processing Systems, 36, 53728-53741.
- https://pettingzoo.farama.org/environments/sisl/
- Plaat, A. (2022). Deep reinforcement learning (Vol. 10, pp. 978-981). Singapore: Springer.
- Zhang, K., Yang, Z., & Başar, T. (2021). Multi-agent reinforcement learning: A selective overview of theories and algorithms. Handbook of reinforcement learning and control, 321-384.
- Von Neumann, J. (1928). Zur theorie der gesellschaftsspiele. Mathematische annalen, 100(1), 295-320.
- Von Neumann, J., & Morgenstern, O. (1944). Theory of Games and Economic Behavior. Princeton University Press.
- Nash Jr, J. F. (1950). Equilibrium points in n-person games. Proceedings of the national academy of sciences, 36(1), 48-49.
- AI Learns to Play Soccer (and breaks physics) https://www.youtube.com/watch?v=ta99S6Fh53c
- AI Learns to Escape Extreme Maze https://www.youtube.com/watch?v=F6iVsA47qiM


UBA FIUBA FACULTAD DE INGENIERÍA

# REFERENCIAS BIBLIOGRÁFICAS Y WEB (I)


- Seuken, S.; Zilberstein, S. Formal models and algorithms for decentralized decision making under uncertainty. Auton. Agents Multi-Agent Syst. 2008, 17, 190–250.
- Bernstein, D. S., Givan, R., Immerman, N., & Zilberstein, S. (2002). The complexity of decentralized control of Markov decision processes. Mathematics of operations research, 27(4), 819-840.
- Liu, Y., Li, X., Wang, J., Wei, F., & Yang, J. (2024). Reinforcement-Learning-Based Multi-UAV Cooperative Search for Moving Targets in 3D Scenarios. Drones, 8(8), 378.
- https://magent2.farama.org/
- Lanctot, M., Lockhart, E., Lespiau, J. B., Zambaldi, V., Upadhyay, S., Pérolat, J., ... & Ryan-Davis, J. (2019). OpenSpiel: A framework for reinforcement learning in games. arXiv preprint arXiv:1908.09453.
- Leibo, J. Z., Dueñez-Guzman, E. A., Vezhnevets, A., Agapiou, J. P., Sunehag, P., Koster, R., ... & Graepel, T. (2021, July). Scalable evaluation of multi-agent reinforcement learning with melting pot. In International conference on machine learning (pp. 6187-6199). PMLR.
- https://pettingzoo.farama.org/environments/mpe/simple_spread/
- https://github.com/google-deepmind/meltingpot
- SMAC: The StarCraft Multi-Agent Challenge https://www.youtube.com/watch? v=VZ7zmQ_obZ0
- Multi-Agent Hide and Seek https://www.youtube.com/watch?v=kopoLzvh5jY AI Olympics (multi-agent reinforcement learning) https://www.youtube.com/watch?v=pJPdW8WWAso

# REFERENCIAS BIBLIOGRÁFICAS Y WEB (I)


- https://github.com/google-deepmind/open_spiel/blob/master/docs/ games.md#negotiation
- https://pettingzoo.farama.org/environments/butterfly/pistonball/
- https://sumo.dlr.de/docs/Theory/Traffic_Simulations.html
- Bain, M., & Sammut, C. (1995, July). A Framework for Behavioural Cloning. In Machine intelligence 15 (pp. 103-129).
- Russell, S. (1998, July). Learning agents for uncertain environments. In Proceedings of the eleventh annual conference on Computational learning theory (pp. 101-103).
- Murphy, K. P. (2023). Probabilistic machine learning: Advanced topics. MIT press.
- Ng, A. Y., & Russell, S. (2000, June). Algorithms for inverse reinforcement learning. In Icml (Vol. 1, No. 2, p. 2).
- Russell, S. (2019). Human compatible: AI and the problem of control. Penguin Uk.
- Ho, J., & Ermon, S. (2016). Generative adversarial imitation learning. Advances in neural information processing systems, 29.